

Universidade Federal do Ceará
Centro de Tecnologia
Departamento de Engenharia de Teleinformática

Alisson Jaime Sales Barros

Projeto Final:
**Detecção de anomalias em sinais de ECG via classificação de classe
única**

Fortaleza
julho de 2026

Alisson Jaime Sales Barros

Projeto Final:
Detecção de anomalias em sinais de ECG via classificação de classe única

Relatório do Projeto Final apresentado às disciplinas TI0097 – Introdução ao Reconhecimento de Padrões e TI0178 – Projeto Integrador III, ministradas pelo Prof. Dr. Guilherme de Alencar Barreto.

Universidade Federal do Ceará
Centro de Tecnologia
Departamento de Engenharia de Teleinformática

Fortaleza
julho de 2026

Resumo

Este relatório trata da detecção de anomalias em batimentos de ECG como um problema de classificação de classe única, usando a base ECG5000. Os batimentos normais são as instâncias negativas e os anômalos, as positivas. De cada batimento extraem-se atributos no domínio do tempo e no domínio da frequência, e comparam-se três detectores: distância euclidiana ao centróide dos normais, distância de Mahalanobis e erro de reconstrução por PCA (autoencoder linear). Os detectores são treinados só com batimentos normais e avaliados em 100 rodadas, antes e depois da redução de dimensionalidade via PCA. O detector de Mahalanobis com atributos de tempo obteve o melhor desempenho (F1 de 0,94 e AUC de 0,96), e os atributos de tempo superaram os de frequência, o que é compatível com a natureza morfológica das anomalias da base.

Palavras-chave: detecção de anomalias; classe única; ECG; distância de Mahalanobis; PCA.

Sumário

1	Introdução	4
1.1	Biossinal e base de dados	4
2	Extração de atributos	4
3	Posto da matriz de dados	5
4	Detectores sem redução de dimensionalidade	5
4.1	Detectores implementados	5
4.2	Limiar de anomalia	5
4.3	Protocolo experimental	6
4.4	Resultados	6
4.4.1	Discussão	6
5	Detectores com redução de dimensionalidade via PCA	7
6	Curva ROC do melhor detector	8
7	Conclusão	8


1 Introdução

Este é o relatório do Projeto Final das disciplinas TI0097 e TI0178. O objetivo é desenvolver e avaliar detectores de anomalias em um problema de classificação de classe única sobre biossinais, e comparar esses detectores para técnicas diferentes de extração de atributos (tempo e frequência) e antes e depois da redução de dimensionalidade via PCA.

1.1 Biossinal e base de dados

Foi escolhido o sinal de eletrocardiograma (ECG) e a base ECG5000, uma das mais usadas na literatura de detecção de anomalias em batimentos cardíacos. A base tem 4998 batimentos já segmentados e reamostrados para 140 amostras cada, rotulados como normais ou anômalos. No problema de classe única deste trabalho, os batimentos normais são as instâncias negativas (2919 exemplos) e os anômalos, as positivas (2079 exemplos). A Figura 1 mostra um batimento de cada tipo.

Figura 1 – Exemplos de batimento normal (negativo) e anômalo (positivo) da base ECG5000.



Fonte: elaborada pelo autor.

Os experimentos foram feitos em Python 3 com `numpy`, `scipy` e `matplotlib`. O código está disponível em:

<https://colab.research.google.com/drive/1KZCGpHibEiAEFDR2i09QS4a1orlk4vfa?usp=sharing>

2 Extração de atributos

De cada batimento, uma série de 140 amostras, extraiu-se um vetor de atributos, formando a matriz de dados $\mathbf{X} \in \mathbb{R}^{N \times p}$ com $N = 4998$. Para permitir a comparação pedida no enunciado, extraíram-se dois conjuntos de atributos.

No **domínio do tempo** ($p = 20$): média, desvio-padrão, variância, valor RMS, mínimo, máximo, amplitude pico-a-pico, mediana, desvio absoluto médio, assimetria, curtose, energia, variação média absoluta, taxa de cruzamentos por zero, 1º e 3º quartis, amplitude interquartilica e os três parâmetros de Hjorth (atividade, mobilidade e complexidade).

No **domínio da frequência** ($p = 15$): a partir da densidade espectral de potência (periodograma via FFT), extraíram-se potência total, centroide espectral, espalhamento

espectral, entropia espectral, frequência de pico, frequência mediana, planura espectral, potência relativa em 5 bandas e máximo, média e desvio-padrão do espectro.

Os atributos foram padronizados por *z-score*, com média e desvio estimados apenas no conjunto de treino de cada rodada. Como aponta o enunciado, o detector euclidiano é sensível à normalização; entre as opções testadas (sem normalização, *min-max* e *z-score*), a padronização *z-score* deu o melhor desempenho, por colocar atributos de escalas muito diferentes, como energia e assimetria, em pé de igualdade nas distâncias.

3 Posto da matriz de dados

Os postos das matrizes de atributos são: no domínio do tempo, $\mathbf{X}$ é 4998×20 com posto $r = 15$; no domínio da frequência, $\mathbf{X}$ é 4998×15 com posto $r = 14$. Nos dois casos o posto é menor que o número de colunas p , ou seja, alguns atributos são combinações lineares de outros e há redundância na representação. No conjunto de tempo, por exemplo, variância, desvio-padrão e atividade de Hjorth carregam a mesma informação; no de frequência, as potências relativas das bandas somam a unidade, o que cria uma dependência linear exata.

Esse número é útil por dois motivos. Ele indica a dimensionalidade intrínseca dos dados, ou seja, bastam r atributos para representá-los sem perda, o que motiva a redução de dimensionalidade da Seção 5. E, mais importante aqui, o posto deficiente faz a matriz de covariância dos atributos ter posto $\leq r < p$, sendo portanto singular e não invertível, o que afeta o detector de Mahalanobis e exige regularização. É o mesmo fenômeno estudado no 2º Trabalho Computacional.

4 Detectores sem redução de dimensionalidade

4.1 Detectores implementados

Cada detector calcula um escore de anomalia $s(\mathbf{x})$ e o compara a um limiar τ ; se $s(\mathbf{x}) > \tau$, a instância é classificada como anomalia.

O detector de **distância euclidiana** usa a distância euclidiana quadrática ao centróide $\mathbf{m}$ dos dados normais de treino, $s(\mathbf{x}) = \|\mathbf{x} - \mathbf{m}\|^2$.

O detector de **distância de Mahalanobis** usa $s(\mathbf{x}) = (\mathbf{x} - \mathbf{m})^\top \mathbf{C}^{-1}(\mathbf{x} - \mathbf{m})$, com $\mathbf{C}$ igual à matriz de covariância dos dados normais de treino. Como $\mathbf{C}$ é singular (Seção anterior), aplicou-se a regularização de Tikhonov $\mathbf{C} + \lambda \mathbf{I}$, com o menor λ que torna a matriz bem-condicionada, o mesmo mecanismo do 2º Trabalho Computacional.

O detector de **PCA (autoencoder linear)** projeta a instância centrada no subespaço dos q primeiros componentes principais dos dados normais e a reconstrói; o escore é o erro de reconstrução quadrático $s(\mathbf{x}) = \|\mathbf{x} - \hat{\mathbf{x}}\|^2$. Reteve-se o número de componentes correspondente a 95% da variância ($q = 9$ para os atributos de tempo). Anomalias, por não pertencerem ao subespaço aprendido com os dados normais, tendem a ter erro de reconstrução alto.

4.2 Limiar de anomalia

Seguindo o enunciado, o limiar τ de cada detector foi definido como o percentil 95 dos escores das instâncias de treino, isto é, a distância quadrática para os detectores de distância ou o erro de reconstrução quadrático para o PCA. Isso equivale a admitir 5% de falsos positivos sobre os dados normais de treino.

4.3 Protocolo experimental

Foram feitas $N_r = 100$ rodadas independentes. Em cada rodada, 80% dos batimentos normais foram usados para treinar os detectores e definir o limiar; os 20% restantes dos normais, junto com todas as anomalias, formaram o conjunto de teste. Como positivo é anomalia, a sensibilidade mede a fração de anomalias detectadas e a especificidade, a fração de batimentos normais classificados corretamente.

4.4 Resultados

A Tabela 1 traz as figuras de mérito médias, com desvio-padrão, das 100 rodadas, para os dois domínios de atributos.

Tabela 1 – Resultados médios (100 rodadas) dos detectores sem redução de dimensionalidade.

Atributos	Detector	Acurácia	Sensib.	Especif.	Precisão	F1	Tempo (ms)
Tempo	Euclidiana	$0,719 \pm 0,009$	$0,654 \pm 0,014$	$0,950 \pm 0,010$	$0,979 \pm 0,004$	$0,784 \pm 0,009$	1,1
	Mahalanobis	$0,908 \pm 0,005$	$0,897 \pm 0,009$	$0,949 \pm 0,010$	$0,984 \pm 0,003$	$0,938 \pm 0,004$	7,4
	PCA ($q=9$)	$0,598 \pm 0,022$	$0,500 \pm 0,029$	$0,949 \pm 0,009$	$0,972 \pm 0,004$	$0,660 \pm 0,026$	5,1
Frequência	Euclidiana	$0,238 \pm 0,002$	$0,039 \pm 0,002$	$0,949 \pm 0,011$	$0,732 \pm 0,037$	$0,073 \pm 0,003$	0,9
	Mahalanobis	$0,341 \pm 0,009$	$0,171 \pm 0,014$	$0,948 \pm 0,011$	$0,921 \pm 0,011$	$0,288 \pm 0,020$	6,7
	PCA ($q=6$)	$0,336 \pm 0,008$	$0,164 \pm 0,011$	$0,948 \pm 0,011$	$0,919 \pm 0,014$	$0,279 \pm 0,016$	3,8

Fonte: elaborada pelo autor.

4.4.1 Discussão

A especificidade ficou perto de 95% em todos os casos, o que é consequência direta do limiar (percentil 95 sobre os normais). O que separa os detectores é a sensibilidade, a capacidade de flagrar anomalias. Nesse ponto o Mahalanobis é o melhor, pois normaliza as distâncias pela covariância dos dados normais e leva em conta as correlações entre atributos; o euclidiano trata os atributos como independentes e de igual peso, sendo menos eficaz; e o detector por PCA ficou abaixo, o que indica que várias anomalias ainda são bem reconstruídas pelo subespaço principal dos normais.

O tipo de atributo teve forte efeito: os de tempo superaram os de frequência (F1 de 0,94 contra 0,29 no melhor detector). Isso combina com a base, cujas anomalias são morfológicas, alterações no formato e na amplitude do batimento, bem captadas por atributos temporais, mas pouco distinguíveis no espectro de potência global, que descarta a informação de forma da onda.


Em todas as figuras de mérito o melhor detector foi o de Mahalanobis com atributos de tempo (acurácia 90,8%, sensibilidade 89,7%, F1 0,938). Em tempo de execução, o mais rápido foi o euclidiano (cerca de 1 ms), por só calcular um centróide; o Mahalanobis é cerca de 7 vezes mais lento, por causa da estimação e inversão da covariância, mas seu custo absoluto de poucos milissegundos por rodada é aceitável, o que o mantém como melhor detector no conjunto.

Sobre a inversão da matriz de covariância: como o posto de $\mathbf{X}$ é deficiente, a covariância dos dados normais é singular. O problema foi resolvido com a regularização de Tikhonov ($\mathbf{C} + \lambda \mathbf{I}$), com λ igual ao menor valor, em potências de 10 a partir de uma fração do traço, que eleva o recíproco do número de condicionamento acima de 10^{-10} . Isso adiciona uma pequena constante à diagonal, completa o posto e estabiliza a inversão, sem alterar muito a geometria dos dados.

5 Detectores com redução de dimensionalidade via PCA

Nesta etapa só os detectores de distância foram avaliados, com PCA como redutor de dimensionalidade sobre os atributos de tempo, o melhor domínio da seção anterior. Escolheu-se o número de componentes q que preserva ao menos 95% da variância, usando o conjunto de treino da primeira rodada. A Figura 2 mostra a variância explicada acumulada $VE(q)$.

Figura 2 – Variância explicada acumulada $VE(q)$ em função do número de componentes.



Fonte: elaborada pelo autor.

A $VE(q)$ satura em 100% já em $q = 15$, exatamente o posto da matriz, pois as 5 direções restantes têm variância nula. O valor escolhido foi $q = 9$, que preserva 96,8% da variância. A Tabela 2 traz os resultados com a redução.

Tabela 2 – Resultados médios (100 rodadas) dos detectores de distância com redução PCA ($q = 9$).

Detector	Acurácia	Sensib.	Especif.	Precisão	F1	Tempo (ms)
Euclidiana+PCA	0,712 ± 0,010	0,645 ± 0,016	0,950 ± 0,011	0,979 ± 0,004	0,777 ± 0,010	0,9
Mahalanobis+PCA	0,916 ± 0,003	0,906 ± 0,006	0,949 ± 0,009	0,985 ± 0,003	0,944 ± 0,002	4,0


Fonte: elaborada pelo autor.

A dimensão escolhida foi $q = 9$ componentes, o que corresponde a preservar cerca de 96,8% da variância original dos atributos de tempo. Não houve piora; ao contrário, houve leve melhora. Para o Mahalanobis, a F1 subiu de 0,938 para 0,944 e a acurácia de 90,8% para 91,6%, e o euclidiano manteve praticamente o mesmo desempenho. Além disso, o tempo de execução do Mahalanobis quase caiu à metade (de 7,4 ms para 4,0 ms), por operar em dimensão menor. A melhora do Mahalanobis se explica porque a redução PCA elimina as direções de variância quase nula responsáveis pela singularidade da covariância; a projeção funciona, na prática, como uma regularização, e dá uma estimativa de covariância mais estável no subespaço retido.

6 Curva ROC do melhor detector

A Figura 3 traz a curva ROC do melhor detector, o de Mahalanobis com atributos de tempo, obtida variando o limiar τ ao longo de toda a faixa de escores.

Figura 3 – Curva ROC do detector de Mahalanobis (atributos de tempo).



Fonte: elaborada pelo autor.

A área sob a curva foi $AUC = 0,962$, próxima de 1, o que confirma a boa capacidade de separação do detector: a curva sobe rápido e chega a sensibilidade acima de 90% com taxa de falsos positivos abaixo de 5%. A ROC também mostra que o ponto de operação usado nas Tabelas 1 e 2 (percentil 95, ou seja, falsos positivos perto de 5%) fica na região de joelho da curva, um bom equilíbrio entre sensibilidade e especificidade.

7 Conclusão

O problema de detectar batimentos anômalos de ECG foi formulado como classificação de classe única, com a base ECG5000. A técnica de extração de atributos foi determinante: os atributos de tempo superaram os de frequência (F1 0,94 contra 0,29), por captarem as alterações morfológicas que caracterizam as anomalias. Entre os detectores, o de Mahalanobis foi o melhor em todas as figuras de mérito, acima do euclidiano, que ignora correlações, e do baseado em PCA; o euclidiano foi o mais rápido, mas o custo do Mahalanobis é aceitável. O posto deficiente da matriz de dados tornou a covariância singular, e a inversão foi viabilizada pela regularização de Tikhonov, retomando o conteúdo do 2º Trabalho Computacional. A redução de dimensionalidade via PCA ($q = 9$, 96,8% da variância) não piorou o desempenho, e ainda reduziu o tempo de execução, por remover as direções redundantes que atrapalhavam a estimação da covariância. O melhor detector alcançou $AUC = 0,962$.

Referências

- [1] GOLDBERGER, A. L. *et al.* PhysioBank, PhysioToolkit, and PhysioNet: Components of a New Research Resource for Complex Physiologic Signals. *Circulation*, v. 101, n. 23, p. e215–e220, 2000. Base ECG5000 do *UCR Time Series Classification Archive*.
- [2] CHANDOLA, V.; BANERJEE, A.; KUMAR, V. Anomaly Detection: A Survey. *ACM Computing Surveys*, v. 41, n. 3, p. 1–58, 2009.
- [3] BARRETO, G. A. *Introdução à Classificação de Padrões* (notas de aula). Fortaleza: UFC/DETI, 2026.